

**PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO
CIENTÍFICA E TECNOLÓGICA**

UNIVERSIDADE ESTADUAL DO NORTE FLUMINENSE

DARCY RIBEIRO

Centro CCT

Labotatório LCMAT

Relatório do período: Janeiro 2023 - Outubro 2023

Relatório Anual PIBIC

Bolsista: Daniel Brito dos Santos

Matricula: 00119110393

Orientadora: Prof. Dra. Annabell Del Real Tamariz

Curso: Bacharelado em Ciência da Computação

Título do Projeto: Project-driven *Data Science*: Aprendendo e Mapeando

Título do Plano de Trabalho: Primeiros Passos na Inferência Ativa

Fonte financiadora: PIBIC/UENF

1 Etapas Propostas no Plano de Trabalho

O plano de trabalho deste ano (2023) consistiu na pesquisa bibliográfica exploratória da Inferência Ativa. Nesse sentido, propusemos as seguintes etapas:

- A. Busca exploratória dos artigos;
- B. Leitura sistemática de cada artigo;
- C. Análise comparativa dos achados na leitura;
- D. Consolidação da revisão bibliográfica;
- E. Elaboração do relatório final.

Durante o desenvolvimento deste projeto, o foco da pesquisa evoluiu além do plano de trabalho inicial. Embora as etapas tenham sido seguidas, o processo foi mais exploratório e integrado ao desenvolvimento Trabalho de Conclusão de Curso do bolsista, que se aprofunda na implementação de um modelo computacional de Inferência Ativa. Assim, neste documento apresentamos os nossos achados, apresentando brevemente os principais trabalhos encontrados e estudados, como também consolidando as suas ideias em um marco teórico.

2 Introdução

O conceito de Inferência Ativa busca formalizar o comportamento de sistemas dinâmicos, principalmente sistemas que apresentam de ação, percepção e aprendizado. A ideia central é que qualquer sistema dinâmico não estacionário para permanecer existindo necessita ter como ímpeto principal a minimização de sua energia livre. Desse modo, necessariamente o sistema necessita de algum tipo de representação do seu externo. O conceito de Inferência Ativa afirma que modelos de inferência são suficientes para modelar esse princípio e portanto modelar comportamento de sistemas muito mais complexos como braços robóticos e cérebros. (FRISTON; SAMOTHRAKIS; MONTAGUE, 2012; FRISTON et al., 2015; FRISTON et al., 2017)

Segundo (HEINS et al., 2022b), a pesquisa acadêmica sobre as aplicações da Inferência Ativa está em franca expansão nos mais diversos campos, dentre eles podemos citar:

- Modelagem de comportamento humano e animal (ADAMS et al., 2021; HOLMES et al., 2021; PARR et al., 2020)
- Neurociência cognitiva, especialmente tomada de decisão sob incerteza (SCHWARTENBECK et al., 2015; SMITH et al., 2020; SMITH et al., 2021)
- Modelos computacionais de psicopatologia (MONTAGUE et al., 2012; SMITH et al., 2021)
- Control Theory, área da engenharia que se ocupa de algoritmos e controladores para sistemas dinâmicos, desde braços robóticos até telecomunicações e foguetes (BAIOUMY et al., 2022; BALTIERI; BUCKLEY, 2019; MILLIDGE et al., 2020)
- Aprendizado de máquina por reforço (FOUNTAS et al., 2020; MILLIDGE et al., 2020; SAJID et al., 2021; TSCHANTZ et al., 2020a; TSCHANTZ et al., 2020c)
- Cognição social (ADAMS et al., 2021; TISON; POIRIER, 2021; WIRKUTTIS; TANI, 2021)

Mais recentemente (KAGAN et al., 2022) demonstrou que uma cultura de células corticais demonstraram aprendizado a partir de estímulos previsíveis e imprevisíveis exatamente como sugere a teoria. O que reforça a ideia de que o princípio da inferência ativa pode ser uma chave importante para compreender a cognição como fenômeno, tanto biológico, como talvez computacional. E que ela pode possivelmente explicar e permitir a geração de sistemas capazes de aprendizado e tomada de decisões.

Considerando a velocidade de desenvolvimento e os resultados relevantes que essa área tem apresentado mesmo sendo tão recente, entendemos que pode ser uma grande oportunidade para novos pesquisadores contribuírem com a sua consolidação.

Nessa primeira incursão buscamos efetuar uma revisão bibliográfica dos artigos mais relevantes dessa área tendo em vista construir um mapa compreensível da área, buscando especialmente listar as lacunas e oportunidades de pesquisa como perguntas não respondidas e áreas pouco exploradas.

3 Objetivos

O objetivo principal desta pesquisa é desenvolver uma compreensão aprofundada dos fundamentos teóricos e das aplicações práticas da Inferência Ativa. Isso envolve explorar como esse conceito se aplica não só no campo teórico, mas também em implementações práticas, abrangendo diversos domínios como cognição, comportamento adaptativo, e sistemas autônomos. Os objetivos específicos são:

- Realizar uma revisão bibliográfica exploratória para mapear o estado atual do conhecimento na área de Inferência Ativa.
- Identificar e analisar as principais contribuições teóricas e práticas na literatura, destacando conceitos fundamentais para pesquisa futura.
- Apresentar como a Inferência Ativa pode ser implementada como Processos de Decisão de Markov Parcialmente Observáveis (POMDP), e explorar suas implicações para a modelagem de comportamento adaptativo e aprendizagem em sistemas dinâmicos.

4 Metodologia

Para atingir nosso objetivo de compreender a literatura da Inferência Ativa propomos uma revisão bibliográfica exploratória. Seguimos o seguinte algoritmo para desempenhá-la:

1. Buscar o termo “active inference” nas plataformas: Google Scholar, Semantics Scholar e Scopus. Essas plataformas são buscadores de artigos científicos que oferecem diversas ferramentas para nos auxiliar nessa busca inicial, como a possibilidade de ordenar por número de citação, selecionar autores e filtrar datas de publicação.
2. Selecionar os artigos que julgarmos mais representativos na área, a partir da busca exploratória nas três plataformas. Essa seleção se dará de acordo com o número total de citações de cada um deles, aliado a sua interconexão com os outros, os autores mais relevantes e principalmente a abrangência de sua proposta.
3. Efetuar uma leitura sistemática de cada um dos artigos selecionados buscando extrair seus principais conceitos e apresentar um breve resumo de cada trabalho.
4. Comparar os artefatos extraídos de cada artigo para construir uma análise comparativa da área, a fim de localizar e explicitar os seus principais conceitos.

5 Resultados

5.1 Bibliografia Levantada

Nesta seção, exploramos trabalhos significativos relacionados à Inferência Ativa (AIF) e suas aplicações. Os estudos apresentados estabelecem uma base sólida para compreender o arcabouço teórico da AIF, suas implementações práticas e seu impacto potencial em diversos domínios.

5.1.1 Fundamentos da Inferência Ativa

- Costa et al. (2020). **Active inference on discrete state-spaces: A synthesis.** Da Costa e colaboradores fornecem uma revisão abrangente da teoria e métodos da Inferência Ativa em espaços de estados discretos, abordando conceitos principais e sua relação com outros frameworks, como aprendizado por reforço, inferência bayesiana e teoria da informação.
- Parr, Pezzulo e Friston (2022). **Active Inference: The Free Energy Principle in Mind, Brain, and Behavior.** Parr e colaboradores oferecem uma visão geral da Inferência Ativa como uma teoria geral da mente, cérebro e comportamento, explicando seus princípios-chave e implicações para compreender diversos aspectos da cognição e ação.
- Tschantz et al. (2020b). **Scaling Active Inference.** Tschantz e colaboradores investigam a escalabilidade da Inferência Ativa em diferentes níveis de abstração e complexidade, propondo uma formulação hierárquica que pode lidar com grandes espaços de estados e horizontes temporais extensos.
- Smith, Friston e Whyte (2021). **A Step-by-Step Tutorial on Active Inference and its Application to Empirical Data.** Smith e colaboradores oferecem um tutorial passo a passo sobre como aplicar Inferência Ativa a dados empíricos, guiando o leitor na construção de um modelo de Inferência Ativa, ajustando-o a dados comportamentais e testando suas previsões.

5.1.2 Aplicações

- Kagan et al. (2022). **In vitro neurons learn and exhibit sentience when embodied in a simulated game-world.** Kagan e colaboradores desenvolveram o DishBrain, um sistema que integra neurônios *in vitro* a um mundo simulado inspirado no jogo arcade “Pong”, aplicando conceitos da teoria de AIF. Demonstraram que

neurônios podem exibir comportamento adaptativo e orientado a objetivos, auto-organizando sua atividade e estrutura em resposta a informações sensoriais esparsas fornecidas pelo sistema DishBrain.

- Heins et al. (2022a). **pymdp: A Python library for active inference in discrete state spaces**. Heins e colaboradores apresentam o pymdp, uma biblioteca Python para simular agentes de Inferência Ativa com modelos generativos de espaço de estados discretos. O artigo detalha os princípios teóricos, matemáticos e computacionais por trás da biblioteca, bem como sua motivação e vantagens. Eles também ilustram como a biblioteca pode ser usada para projetar e testar modelos de Inferência Ativa para diversos domínios e tarefas.
- Smith, Badcock e Friston (2021). **Recent advances in the application of predictive coding and active inference models within clinical neuroscience**. Smith e colaboradores revisam avanços recentes na aplicação de modelos de codificação preditiva e inferência ativa à neurociência clínica, discutindo como esses modelos podem elucidar mecanismos neurais subjacentes a diversos distúrbios psiquiátricos.
- Adams et al. (2022). **Everything is connected: Inference and attractors in delusions**. Adams e colaboradores utilizam a inferência ativa para explicar a formação e manutenção de delírios, argumentando que delírios podem ser vistos como crenças anormais que surgem de processos de inferência defeituosos no cérebro.

Os trabalhos selecionados oferecem uma compreensão abrangente dos fundamentos teóricos da AIF e suas aplicações práticas.

5.2 Introdução à Inferência Ativa

Todo organismo precisa interagir com seu ambiente. Isso ocorre por meio de um ciclo contínuo de ação-percepção no qual o organismo **observa** o seu ambiente e **age** de modo a modificá-lo, conforme ilustrado na Figura 1.

Esse ambiente, entretanto, apresenta desafios formidáveis a continuidade de sua existência. Alimentação, hidratação, proteção de predadores, manutenção da integridade física e homeostase são apenas alguns exemplos. Além disso, cada ação gera uma cadeia recursiva de consequências, de modo que existe um vasto campo de ações possíveis no qual apenas um pequeno conjunto de ações são benéficas ao organismo. (SMITH; FRISTON; WHYTE, 2021; TSCHANTZ et al., 2020b)

Desse modo, a única forma de um organismo permanecer existindo é se ele adquirir alguma forma de **controle adaptativo** de seu ciclo de ação-percepção. Nesse sentido, a Inferência Ativa (AIF) é um **princípio normativo** para solucionar esse problema de controle adaptativo. Ou seja, AIF propõem postulados sobre **o que** organismos




Figura 1 – Ciclo de ação-percepção
fonte: (PARR; PEZZULO; FRISTON, 2022)

devem fazer para continuar existindo, e oferece explicação do **porquê** tais postulados o ajudariam nesse objetivo. Além disso, a AIF também oferece uma **teoria de processo** para explicar mecanisticamente **como** organismos podem implementar os postulados normativos. (PARR; PEZZULO; FRISTON, 2022; COSTA et al., 2020)

5.3 Princípios da Inferência Ativa

A ideia fundamental da AIF é que mesmo com as suas variadas manifestações, os elementos centrais do comportamento, cognição, e adaptação de qualquer organismo podem ser compreendidos e explicados por uma única teoria coesa construída a partir de princípios fundamentais (PARR; PEZZULO; FRISTON, 2022; COSTA et al., 2020).

Segundo a AIF, todos são propriedades emergentes de um processo de **inferência** no qual agentes buscam **ativamente** minimizar a “surpresa” (erro de predição) de cada nova percepção sensorial tanto por meio de ações quanto por meio da atualização de suas crenças.

Para tanto, a AIF propõem os seguintes postulados:

- Agentes mantêm um **modelo probabilístico** de mundo representando crenças probabilísticas sobre a dinâmica de estados do seu ambiente, e como tais estados elicitam diferentes percepções sensoriais no agente. Esse modelo é chamado de generativo porque permite ao agente gerar predições quanto às sensações esperadas. (COSTA et al., 2020; TSCHANTZ et al., 2020b; SMITH; FRISTON; WHYTE, 2021)
- Todas as facetas de comportamento e cognição de qualquer organismo seguem um único imperativo: **minimizar a surpresa** das suas observações sensoriais. Surpresa nesse contexto se refere ao erro de predição, a discrepância entre a observação obtida

e a observação esperada segundo o modelo generativo do organismo. (COSTA et al., 2020; PARR; PEZZULO; FRISTON, 2022; SMITH; FRISTON; WHYTE, 2021)

- A surpresa não pode ser minimizada direta nem passivamente, apenas **atualizando as crenças** para se conformarem às observações, ou **agindo** para conformar o ambiente às crenças (PARR; PEZZULO; FRISTON, 2022; COSTA et al., 2020; SMITH; FRISTON; WHYTE, 2021). Dessa forma, agentes **minimizam a surpresa** por meio da otimização de duas funções objetivo complementares (COSTA et al., 2020):
 - **Energia livre variacional (VFE)**, que mede a adequação entre um modelo interno de mundo e as suas observações sensoriais.
 - **Energia livre esperada (EFE)** que classifica possíveis cursos de ação em relação a preferências do agente.
- Fundamentalmente, um modelo de AIF prediz **o que observará** caso escolha uma de uma forma ou de outra. Assim, esses modelos escolhem ações que esperam **gerar observações** de maior preferência, ou que trarão maior quantidade de novas informações. Portanto, as **preferências** e objetivos do agente são codificados como **priors** que representam um viés de otimismo no modelo generativo do agente. Isto é, **observações preferidas são assumidas como mais prováveis**. Esse viés, torna resultados não preferidos como literal e tecnicamente “surpreendentes”, ou seja, desviantes dos **priors** (COSTA et al., 2020; PARR; PEZZULO; FRISTON, 2022; HEINS et al., 2022a; SMITH; BADCOCK; FRISTON, 2021; SMITH; FRISTON; WHYTE, 2021).

Desse modo, se eu estou com fome é mais provável que eu vá procurar comida do que ficar parado, precisamente porque estar com fome é inconsistente com minhas preferências (estatisticamente surpreendente), e eu espero que comer produza sentimentos de saciedade (minimizando a surpresa) (SMITH; BADCOCK; FRISTON, 2021; SMITH; FRISTON; WHYTE, 2021).

Em outras palavras, uma preferência é simplesmente algo que um agente (acredita que) provavelmente buscará (COSTA et al., 2020).

- AIF pode, desse modo, ser compreendida como **minimização da surpresa** por meio da **percepção e ação** com o objetivo de realizar suas preferências e portanto minimizar a surpresa que esperam encontrar no futuro. (COSTA et al., 2020)
- Desse modo, podemos formular o **ciclo de percepção-ação** da seguinte forma:
 1. agentes **percebem o mundo** por meio da minimização da energia livre variacional (**VFE**), garantindo que seu modelo é consistente com suas observações passadas.

2. agentes **agem** minimizando a energia livre esperada (**EFE**), para tornar as **observações futuras** consistentes com o seu modelo.
3. Essa conceituação de comportamento pode ser resumidamente descrita como “**auto-evidenciamento**” (COSTA et al., 2020).

Assim, assumindo as premissas apresentadas, é possível descrever o comportamento de organismos viáveis como performando AIF. Resta apenas o desafio de determinar os processos computacionais e fisiológicos que a implementam (COSTA et al., 2020).

5.4 Inferência Ativa como POMDP

Conforme vimos na seção 5.3, a Inferência Ativa (AIF) é fundamentada na ideia de que tanto a percepção quanto a aprendizagem são processos que visam minimizar uma quantidade denominada energia livre variacional (VFE). Além disso, a seleção de ações, o planejamento e a tomada de decisões são entendidos como processos que buscam minimizar a energia livre esperada (EFE). Esta última quantifica a VFE de diferentes ações com base em resultados futuros esperados.

Nesse sentido, a Inferência Ativa (AIF) é frequentemente formalizada como um Processo de Decisão de Markov Parcialmente Observável (POMDP). Esta abordagem é amplamente aceita na literatura e será a adotada neste trabalho (TSCHANTZ et al., 2020b; SMITH; FRISTON; WHYTE, 2021; COSTA et al., 2020; HEINS et al., 2022a).

Nesta seção, apresentaremos os fundamentos necessários para compreender tal formalização. Apresentaremos os conceitos básicos, modelo generativo, inferência Bayesiana, Distribuição de Reconhecimento, e finalmente as funções de minimização da energia livre esperada.

5.4.1 Conceitos Básicos

- **Estado do Ambiente.** A cada instante t , o **verdadeiro estado** do ambiente $\hat{s}_t \in R^{d_s}$ evolui de acordo com a dinâmica de transição estocástica $\hat{s}_t \sim P(\hat{s}_t | \hat{s}_{t-1}, a_{t-1})$ onde $a \in R^{d_a}$ denota as **ações** do agente.
- **Observações.** Agentes não têm acesso ao verdadeiro **estado do ambiente**, apenas observações $o_t \in R^{d_o}$ geradas a partir do estado real do ambiente: $o_t \sim p(o_t | \hat{s}_t)$.
- **Crenças dos Agentes.** Portanto, a partir das observações, os agentes operam com **crenças** $s_t \in R^{d_s}$ sobre o verdadeiro estado do ambiente \hat{s}_t . Essas crenças são chamadas de “**estados ocultos**” pois dizem respeito a variáveis que o agente não pode observar diretamente mas acredita que existam.

5.4.2 Modelo Generativo

A partir desses conceitos básicos, a AIF propõem que agentes implementam e atualizam um **modelo generativo** do seu ambiente com crenças probabilísticas sobre a dinâmica de estados do seu ambiente, e como tais estados elicitam diferentes percepções sensoriais no agente. Esse modelo é uma distribuição conjunta que especifica como **estados ocultos** causam consequências sensoriais (**observações**). Isto é, $p(\tilde{o}, \tilde{s}, \pi, \theta)$ sobre observações o , estados ocultos s , estados de controle π e parâmetros θ . Onde a notação com til denota uma sequência de variáveis no tempo, π denota uma política (sequência de ações) $\pi = \{a_0, \dots, a_T\}$ e $\theta \in \Theta$ denota os parâmetros do modelo generativo.

5.4.3 Inferência Bayesiana

A partir dessa formalização, a cada nova observação, um agente pode determinar em qual estado o seu ambiente se encontra e qual seria a melhor ação a ser tomada. Isto é, determinar o estado oculto e a ação de acordo com determinada observação, portanto, bastaria “inverter” o seu modelo generativo calculando a posterior: $p(\tilde{s}, \pi, \theta | \tilde{o})$.

Nesse sentido, a **inferência Bayesiana** representa a maneira ótima de inferir tais crenças *a posteriori* dentro de um modelo generativo. Essa inferência é um procedimento estatístico que descreve a maneira ótima de atualizar as crenças (entendidas como distribuições de probabilidade) ao fazer novas observações (ou seja, receber novas entradas sensoriais) com base nas regras da probabilidade. Especificamente, as crenças são atualizadas à luz de novas observações usando o Teorema de Bayes, que pode ser escrito da seguinte forma:

$$p(s|o, m) = \frac{p(o|s, m) \cdot p(s|m)}{p(o|m)} \quad (5.1)$$

Onde:

- $p(s|m)$ indica a probabilidade de diferentes estados possíveis s sob um modelo do mundo m , conhecida como crença *a priori*, ou prévian antes de fazer uma nova observação o .
- $p(o|s, m)$ é o termo de *likelihood* (verossimilhança), que codifica a probabilidade dentro de um modelo m de que uma observação particular o seria feita caso o estado s fosse o estado verdadeiro.
- $p(o|m)$ é a *evidência do modelo* e indica quão consistente uma observação é com um modelo do mundo em geral.
- Finalmente, $p(s|o, m)$ é a crença *a posteriori*, que codifica qual deveria ser a nova crença após fazer uma nova observação.

Em essência, a regra de Bayes descreve como atualizar de forma ótima as crenças à luz de novos dados. Para chegar a uma nova crença (sua *posterior*), você deve: (1) considerar o que você acreditava previamente (sua *prior*), (2) combiná-la com o que você acredita sobre a consistência de uma nova observação com diferentes estados possíveis (sua *likelihood*), e (3) considerar a consistência geral dessa observação com seu modelo.

Porém, o Teorema de Bayes é **computacionalmente intratável** para distribuições que não sejam as mais simples. Principalmente devido à necessidade de calcular o termo $p(o|m)$ (evidência do modelo), que exige a soma das probabilidades de observações para todos os estados possíveis. À medida que o número de dimensões (e possíveis valores) dos estados aumenta, o número de termos que devem ser somados cresce exponencialmente. Dada essa complexidade, técnicas de aproximação, como a Inferência Variacional, são empregadas. (SMITH; FRISTON; WHYTE, 2021)

5.4.4 Distribuição de Reconhecimento

Nesse contexto, a Inferência Variacional é utilizada para aproximar a distribuição *a posteriori* verdadeira com uma distribuição mais simples e tratável, denominada “**distribuição de reconhecimento**”, representada por $q(\hat{s}, \pi, \theta)$. Esta distribuição representa as crenças do agente sobre estados ocultos \hat{s} , políticas π e parâmetros do modelo $\theta \in \Theta$ (TSCHANTZ et al., 2020b).

Dessa forma, além do modelo generativo, os agentes mantêm uma distribuição de reconhecimento que reflete suas crenças atuais sobre os estados ocultos do mundo, dadas suas observações. A Inferência Ativa, portanto, não apenas oferece uma solução normativa para o problema de controle adaptativo, mas também uma solução prática para aproximar a inferência bayesiana dos agentes (PARR; PEZZULO; FRISTON, 2022).

Um exemplo ilustrativo seria um agente em um chuveiro elétrico. O **modelo generativo** representa crenças sobre como os estados do chuveiro levam a diferentes temperaturas da água. A **distribuição de reconhecimento**, por outro lado, apresenta crenças como: ao sentir água gelada, o chuveiro provavelmente está na configuração “desligado”.

5.4.5 Energia Livre Variacional

Conforme novas observações são coletadas, os agentes atualizam os parâmetros de sua distribuição de reconhecimento para minimizar a Energia Livre Variacional (VFE), denotada por \mathcal{F} (COSTA et al., 2020; TSCHANTZ et al., 2020b):

$$\mathcal{F}(\hat{o}) = E_{q(\hat{s}, \pi, \theta)}[\ln q(\hat{s}, \pi, \theta) - \ln p(\tilde{o}, \tilde{s}, \pi, \theta)] \quad (5.2)$$

Minimizar \mathcal{F} faz com que a distribuição de reconhecimento $q(\hat{s}, \pi, \theta)$ convirja para uma aproximação da distribuição *a posteriori* intratável $p(\tilde{s}, \pi, \theta|\tilde{o})$, realizando assim a

inferência Bayesiana aproximada. Desse modo, energia livre atua como uma proxy para quão surpreendente, ou improvável cada observação é, de acordo com o modelo do agente, visto que ela é justamente a medida dessa discrepância.

5.4.6 Energia Livre Esperada

Minimizar a Equação 5.4.5 fornece uma **estimativa** do quão surpreendente determinadas observações são. Porém, para de fato minimizar a surpresa de suas observações, o agente precisam alterar as suas observações por meio de ações. Agir de modo a minimizar a VFE garante a minimização do *surprisal* ($-\ln p(\tilde{o})$), ou a maximização da “evidência de modelo Bayesiana” $p(\tilde{o})$, porque a energia livre é um upper bound do *surprisal*. (TSCHANTZ et al., 2020b)

Nesse sentido, a AIF propõem que agentes selecionam *policies* de modo a minimizar a energia livre esperada (EFE) \mathcal{G} (COSTA et al., 2020) A EFE de determinada *policy* π em determinado instante τ é dada por:

$$\mathcal{G}(\pi, \tau) = E_{q(o_\tau, s_\tau, \theta|\pi)}[\ln q(s_\tau, \theta|\pi) - \ln p(o_\tau, s_\tau, \theta|\pi)] \quad (5.3)$$

Selecionar *policies* que minimizem a Equação 5.4.6 vai garantir que observações prováveis (i.e favoráveis de acordo com as *priors* normativas do agente) serão preferencialmente amostradas, enquanto também garante que agentes colham informações sobre seu ambiente.

Assim, incorporando percepção, planejamento e tomada de decisão, podemos formalizar o ciclo de ação-percepção como (COSTA et al., 2020):

1. Um agente recebe um estímulo,
2. infere as causas latentes desse estímulo,
3. planeja o futuro e,
4. realiza seu curso preferido de ação.

6 Conclusão

Exploramos a teoria da Inferência Ativa (AIF) e sua implementação como Processos de Decisão de Markov Parcialmente Observáveis (POMDP), proporcionando uma visão abrangente de como os agentes podem interagir e aprender com seu ambiente de maneira adaptativa e eficiente.

A AIF surge como uma teoria unificadora que busca explicar a cognição e o comportamento de agentes, propondo que estes buscam ativamente minimizar a surpresa em suas percepções sensoriais. Esta teoria, fundamentada em princípios matemáticos e computacionais sólidos, oferece uma perspectiva normativa sobre como os agentes devem se comportar para garantir sua continuidade em ambientes dinâmicos.

A implementação da AIF como POMDP permitiu uma compreensão mais profunda dos mecanismos pelos quais os agentes podem realizar inferências sobre seu ambiente e tomar decisões baseadas em suas crenças. Discutimos conceitos como modelo generativo, inferência Bayesiana, distribuição de reconhecimento, e as funções de minimização da Energia Livre Variacional (VFE) e Energia Livre Esperada (EFE), destacando como esses elementos se integram para formar um ciclo de percepção-ação coeso.

Nosso trabalho ressaltou a importância de compreender os fundamentos teóricos da AIF e sua implementação como POMDP para avançar nas pesquisas em aprendizado e cognição. A capacidade de modelar o comportamento adaptativo e a aprendizagem de agentes em ambientes complexos e incertos é crucial para o desenvolvimento de sistemas autônomos mais robustos e eficientes.

Em conclusão, a Inferência Ativa e sua implementação como POMDP oferecem uma base teórica e prática promissora para explorar e entender os mecanismos de aprendizagem e tomada de decisão. O aprofundamento e a continuidade das pesquisas nesta área têm o potencial de trazer avanços significativos e inovações para o campo da inteligência artificial e ciências cognitivas.

7 Participação em Congressos e Trabalhos Publicados ou Submetidos e Outras Atividades Acadêmicas

7.1 Participação no CONFICT 2023





7.2 Prêmio de Melhor Trabalho no CONFICT 2023



8 Data e assinatura do bolsista (assinatura digitalizada)

Donel Brito dos Santos

12/11/2023

9 Data e assinatura do orientador (assinatura digitalizada)

Annabell D.R. Tamariz

14/11/2023

Referências

ADAMS, R. A. et al. Everything is connected: Inference and attractors in delusions. *Schizophrenia Research*, Elsevier BV, Jul 2021. Disponível em: <https://doi.org/10.1016/j.schres.2021.07.032>. 3

ADAMS, R. A. et al. Everything is connected: Inference and attractors in delusions. *Schizophrenia Research*, v. 245, p. 5–22, Jul 2022. ISSN 0920-9964. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0920996421003054>. 8

BAIOUMY, M. et al. Towards stochastic fault-tolerant control using precision learning and active inference. In: *Machine Learning and Principles and Practice of Knowledge Discovery in Databases*. Springer International Publishing, 2022. p. 681–691. Disponível em: https://doi.org/10.1007/978-3-030-93736-2_48. 3

BALTIERI, M.; BUCKLEY, C. L. Pid control as a process of active inference with linear generative models. *Entropy*, Multidisciplinary Digital Publishing Institute, v. 21, n. 33, p. 257, Mar 2019. ISSN 1099-4300. Disponível em: <https://www.mdpi.com/1099-4300/21/3/257>. 3

COSTA, L. D. et al. Active inference on discrete state-spaces: A synthesis. *Journal of Mathematical Psychology*, v. 99, p. 102447, Dec 2020. ISSN 0022-2496. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0022249620300857>. 7, 9, 10, 11, 13, 14

FOUNTAS, Z. et al. Deep active inference agents using monte-carlo methods. In: *Advances in Neural Information Processing Systems*. Advances in Neural Information Processing Systems, 2020. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/865dfbde8a344b44095495f3591f7407-Abstract.html>. 3

FRISTON, K. et al. Active Inference: A Process Theory. *Neural Computation*, v. 29, n. 1, p. 1–49, jan. 2017. ISSN 0899-7667. Disponível em: https://doi.org/10.1162/NECO_a.00912. 3

FRISTON, K. et al. Active inference and epistemic value. *Cognitive Neuroscience*, v. 6, n. 4, p. 187–214, out. 2015. ISSN 1758-8928. Publisher: Routledge. eprint: <https://doi.org/10.1080/17588928.2015.1020053>. Disponível em: <https://doi.org/10.1080/17588928.2015.1020053>. 3

FRISTON, K.; SAMOTHRAKIS, S.; MONTAGUE, R. Active inference and agency: optimal control without cost functions. *Biological Cybernetics*, v. 106, n. 8, p. 523–541, out. 2012. ISSN 1432-0770. Disponível em: <https://doi.org/10.1007/s00422-012-0512-8>. 3

HEINS, C. et al. pymdp: A python library for active inference in discrete state spaces. *Journal of Open Source Software*, v. 7, n. 73, p. 4098, May 2022. ISSN 2475-9066. ArXiv:2201.03904 [cs, q-bio]. Disponível em: <http://arxiv.org/abs/2201.03904>. 8, 10, 11

HEINS, C. et al. pymdp: A Python library for active inference indiscrete state spaces. *Journal of Open Source Software*, v. 7, n. 73, p. 4098, maio 2022. ISSN 2475-9066. Disponível em: <https://joss.theoj.org/papers/10.21105/joss.04098>. 3

HOLMES, E. et al. Active inference, selective attention, and the cocktail party problem. *Neuroscience & Biobehavioral Reviews*, Elsevier, Sep 2021. Disponível em: <https://doi.org/10.1016/j.neubiorev.2021.09.038>. 3

KAGAN, B. J. et al. In vitro neurons learn and exhibit sentience when embodied in a simulated game-world. *Neuron*, p. S0896627322008066, Oct 2022. ISSN 08966273. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S0896627322008066>. 3, 7

MILLIDGE, B. et al. On the relationship between active inference and control as inference. In: *International Workshop on Active Inference*. Springer International Publishing, 2020. p. 3–11. Disponível em: https://doi.org/10.1007/978-3-030-64919-7_1. 3

MONTAGUE, P. R. et al. Computational psychiatry. *Trends in Cognitive Sciences*, Elsevier Ltd, Jan 2012. Disponível em: <https://doi.org/10.1016/j.tics.2011.11.018>. 3

PARR, T.; PEZZULO, G.; FRISTON, K. J. *Active Inference: The Free Energy Principle in Mind, Brain, and Behavior*. The MIT Press, 2022. ISBN 9780262369978. Disponível em: <https://doi.org/10.7551/mitpress/12441.001.0001>. 7, 9, 10, 13

PARR, T. et al. Prefrontal computation as active inference. *Cerebral Cortex*, Oxford University Press, Mar 2020. Disponível em: <https://doi.org/10.1093/cercor/bhz118>. 3

SAJID, N. et al. Active inference: Demystified and compared. *Neural Computation*, MIT Press, Mar 2021. Disponível em: https://doi.org/10.1162/neco_a.01357. 3

SCHWARTENBECK, P. et al. The dopaminergic midbrain encodes the expected certainty about desired outcomes. *Cerebral Cortex*, Oxford University Press, Sep 2015. Disponível em: <https://doi.org/10.1093/cercor/bhu159>. 3

SMITH, R.; BADCOCK, P.; FRISTON, K. J. Recent advances in the application of predictive coding and active inference models within clinical neuroscience. *Psychiatry and Clinical Neurosciences*, v. 75, n. 1, p. 3–13, 2021. ISSN 1440-1819. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1111/pcn.13138>. 8, 10

SMITH, R.; FRISTON, K.; WHYTE, C. A step-by-step tutorial on active inference and its application to empirical data. PsyArXiv, Jan 2021. Disponível em: <https://psyarxiv.com/b4jm6/>. 7, 8, 9, 10, 11, 13

SMITH, R. et al. Greater decision uncertainty characterizes a transdiagnostic patient sample during approach-avoidance conflict: A computational modelling approach. *Journal of Psychiatry & Neuroscience*, Canadian Medical Association, Jan 2021. Disponível em: <https://doi.org/10.1503/jpn.200032>. 3

SMITH, R. et al. Imprecise action selection in substance use disorder: Evidence for active learning impairments when solving the explore-exploit dilemma. *Drug and Alcohol Dependence*, Elsevier, Dec 2020. Disponível em: <https://doi.org/10.1016/j.drugalcdep.2020.108208>. 3

TISON, R.; POIRIER, P. Communication as socially extended active inference: An ecological approach to communicative behavior. *Ecological Psychology*, Taylor & Francis, Apr 2021. Disponível em: <https://doi.org/10.1080/10407413.2021.1965480>. 3

TSCHANTZ, A. et al. Scaling active inference. In: *2020 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2020. p. 1–8. Disponível em: <https://doi.org/10.1109/IJCNN48605.2020.9207382>. 3

TSCHANTZ, A. et al. Scaling active inference. In: *2020 International Joint Conference on Neural Networks (IJCNN)*. [S.l.: s.n.], 2020. p. 1–8. ISSN 2161-4407. 7, 8, 9, 11, 13, 14

TSCHANTZ, A. et al. Reinforcement learning through active inference. In: *Bridging AI and Cognitive Science at the International Conference on Learning Representations*. Bridging AI and Cognitive Science at the International Conference on Learning Representations, 2020. Disponível em: https://baicsworkshop.github.io/pdf/BAICS_37.pdf. 3

WIRKUTTIS, N.; TANI, J. Leading or following? dyadic robot imitative interaction using the active inference framework. *IEEE Robotics and Automation Letters*, IEEE, Apr 2021. Disponível em: <https://doi.org/10.1109/LRA.2021.3090015>. 3